学校代码：11068

学号：202152320222

密级：

郑州工程技術学院

（ 2025 ）届毕业设计（论文）

基于计算机视觉的驾驶员行为监测系统设计与实现

作者姓名：马晓冉

导师姓名：黄继海

学科门类：工学

专业名称：智能科学与技术

培养学院：信息工程学院

完成时间：2025 年 5 月

郑州工程技术学院

学位论文原创性声明

本人郑重声明：所呈交的学位论文是本人在导师的指导下独立进行研究所取得的研究成果。除文中已经加以标注引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的作品成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

作者签名：马晓冉　　日期：2025 年 5 月 20 日

郑州工程技术学院

学位论文版权使用授权书

本学位论文作者完全了解学校有关保留、使用学位论文的规定，同意学校保留并向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅。本人授权郑州工程技术学院可以将本学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编本学位论文。

本学位论文属于

1、保密□，在____年解密后适用本授权书。

2、不保密☑。

（请在以上相应方框内打“√”）

作者签名：马晓冉　　日期：2025 年 5 月 20 日

导师签名：黄纯海　　日期：2025 年 5 月 20 日

目　　录

摘　要 III
ABSTRACT IV
1 绪论 1
1.1 研究背景与意义 1
1.2 国内外研究现状 2
1.2.1 国外研究现状 2
1.2.2 国内研究现状 2
1.2.3 研究现状小结 3
1.3 论文的主要工作 3
1.4 章节安排 4
2 相关技术背景 4
2.1 Dlib 简介 4
2.2 目标检测算法 YOLO 4
2.3 注意力机制 5
2.3.1 SE 注意力机制 5
2.3.1 CBAM 注意力机制 6
3 驾驶员行为监测系统设计 7
3.1 系统总体设计 7
3.1.1 系统架构 7
3.1.2 主界面设计 8
3.2 疲劳行为检测模块 10
3.2.1 疲劳行为检测流程 10
3.2.2 疲劳行为检测算法 11
3.2.3 疲劳判定标准 19
3.3 分心行为检测模块 20
3.3.1 分心行为检测流程 20
3.3.2 分心行为检测算法 22

3.4 本章小结 23
4 训练与分析 24
4.1 前期准备 24
4.1.1 环境准备 24
4.1.2 数据集 25
4.2 训练过程 27
4.2.1 训练模型 27
4.2.2 评估模型 27
4.2.3 改进模型 29
4.3 训练结果与分析 30
5 总结与展望 32
5.1 总结 32
5.2 不足与展望 32
致 谢 34
参考文献 35

摘 要

随着道路交通流量的增加，驾驶员在行车过程中出现的疲劳和分心行为成为交通事故的重要诱因。传统的检测方法主要依靠车辆的运行参数或佩戴专用设备，使用不便且难以实现对多种危险行为的实时识别。针对上述问题，设计并实现了一种基于计算机视觉的驾驶员行为监测系统。

本系统由疲劳行为和分心行为检测两个核心功能构成。疲劳行为检测利用 Dlib 提取驾驶员脸部关键点，通过计算眼睛纵横比、嘴巴纵横比及头部欧拉角，依据眨眼频率、打哈欠频率等关键指标，综合判断驾驶员的疲劳行为。分心行为检测基于 YOLOv5s 引入 SE 和 CBAM 注意力机制改进模型，增强模型对关键特征的关注能力，从而有效识别驾驶员使用手机、喝水、抽烟的分心行为。

本系统界面由 PySide6 构建，支持多种输入方式，并提供参数设置、实时状态显示和预警提醒等功能，操作简单，增强了系统的可用性和用户体验。实验表明，疲劳行为检测在不同光照条件下仍可以准确识别眨眼、打哈欠等疲劳特征；改进后的模型在分心行为识别任务中表现优异，精确率和召回率分别为 96.4%和 93%，展现出较高的检测精度与稳定性。

关键词：疲劳检测；注意力机制；分心行为识别

Design and Implementation of a Driver Behavior Monitoring System Based on Computer Vision

ABSTRACT

With the increasing volume of road traffic, driver fatigue and distraction have become major causes of serious traffic accidents. Traditional detection methods mainly rely on vehicle operation parameters or require the driver to wear specialized equipment, which are inconvenient to use and difficult to achieve real-time recognition of multiple hazardous behaviors. To address these issues, a driver behavior monitoring system based on computer vision has been designed and implemented.

The system consists of two core modules: fatigue behavior detection and distraction behavior detection. The fatigue detection module uses Dlib to extract facial landmarks of the driver. By calculating the eye aspect ratio, mouth aspect ratio, and head Euler angles, it evaluates key indicators such as blink frequency and yawning frequency to comprehensively determine the driver's fatigue state. The distraction detection module is based on an improved YOLOv5s model integrated with SE and CBAM attention mechanisms, which enhance the model’s focus on critical features, enabling effective recognition of distracted behaviors such as using a mobile phone, drinking, and smoking.

The system interface is developed with PySide6, supporting various input methods and offering features such as parameter settings, real-time status display, and alert notifications. The simple operation greatly improves the usability and user experience of the system. The experiments demonstrate that the fatigue detection module can accurately recognize fatigue features like blinking and yawning under different lighting conditions. The improved model performs excellently in distraction detection tasks, with a precision of 96.4% and a recall of 93%, demonstrating high accuracy and stability.

Key words: Fatigue Detection; Attention Mechanism; Distraction Behavior Recognition

基于计算机视觉的驾驶员行为监测系统设计与实现

马晓冉 202152320222

1 绪论

1.1 研究背景与意义

近年来，随着我国经济的稳步增长和居民生活标准的提高，汽车逐渐普及至千家万户，成为大众日常生活中不可或缺的交通工具。如图 1.1 所示，机动车数量持续增长，截至 2024 年，全国机动车总量已达到 4.53 亿辆，其中汽车保有量为 3.53 亿辆；驾驶人数量超过 5.42 亿，其中持有汽车驾照的人数达 5.06 亿人[1]。汽车的普及在方便大家出行的同时，也让交通安全问题变得越来越突出，特别是驾驶过程中出现的疲劳驾驶、注意力不集中等异常行为，已经成了造成交通事故的重要原因之一。

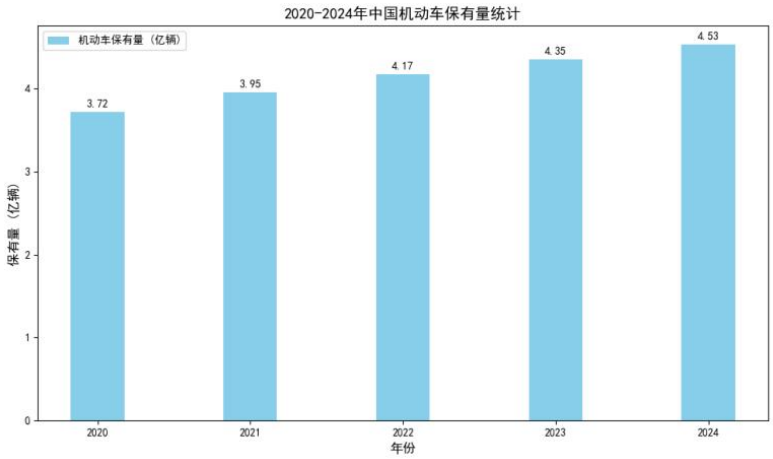

图 1.1 机动车保有量统计图

据国家统计局发布的统计结果显示[2]，2024 年全国范围内出现的交通事故近 24 万起，导致超过 6 万人死亡，另有超过 27 万人受伤。交通事故带来的不仅是个人和家庭层面的沉重损失，也给国家社会在经济与公共安全领域造成了极大压力与挑战。

在诸多诱因中，驾驶员异常行为无疑是最不可忽视的一类，常见的有疲劳驾驶和分心驾驶两种类型[3]。前者多见于长时间连续驾驶或作息不规律的情况下，导致司机反应迟钝、警觉性下降；后者则是指司机在行驶途中做与驾驶无关的动作，比如低头看手机、喝水甚至抽烟。这些看似“顺手”的行为，往往会在关键时刻错失判断和反

应的最佳时机，大大提升了事故发生的风险。

与传统依赖硬件传感器的检测方式相比，基于视觉的行为监测不仅具备非接触、信息丰富的优势，还在成本控制和系统部署上更具灵活性。这对于普通家用车辆乃至商用车队管理系统来说，都具备广泛的应用前景。

本系统旨在设计和实现一个基于计算机视觉的驾驶员行为监测系统，该系统综合利用计算机视觉、图形用户界面开发等技术手段，实现对疲劳驾驶和分心行为的自动识别与提示，为驾驶员行为检测提供有力的技术支撑。这有助于减少因驾驶员异常行为导致的交通事故，进而提升交通安全水平，保护人民生命财产安全，促进智能交通系统的健康发展。

1.2 国内外研究现状

1.2.1 国外研究现状

国外在驾驶员行为监测领域起步较早，技术体系相对成熟，尤其在多模态数据融合、深度学习模型设计以及系统集成方面取得了显著进展。

Zhang 等人提出 Interwoven Deep Convolutional Neural Network（Inter CNN）架构[4]，该模型利用多视角摄像头和光流信息融合，通过多层特征融合和时间投票机制，实现了对驾驶员多种行为的实时分类。在模拟驾驶环境中，Inter CNN 对五类聚合行为的分类准确率达到 81.66%，并能在 15 毫秒内完成推理，满足实时性要求。

Kose 等人采用时空融合的卷积神经网络方法[5]，在 Distracted Driver Dataset 上实现了 99.10%的高精度识别，展示了深度学习在分心驾驶检测中的强大能力。

为了提升模型在真实驾驶环境中的适应性，Jha 等人构建了多模态驾驶员监测数据库（MDM）[6]，该数据库涵盖了头部姿态、视线追踪等多种数据，为驾驶员注意力分析提供了丰富的训练资源。该数据库包含 59 名受试者在自然驾驶条件下的数据，支持对驾驶员注意力状态的深入研究。这些研究成果表明，国外在融合多源数据、提升模型鲁棒性和实时性方面取得了重要进展。

1.2.2 国内研究现状

相较于国外研究起步较早、体系较为完善的情况，国内在驾驶员行为监测领域的研究起初发展略显滞后，但随着交通安全问题受到越来越多的关注，该领域近年来已显著加快发展步伐，逐步积累起一批具有代表性的成果。

在疲劳检测方面，曹骏设计的轻量级识别网络通过知识蒸馏技术降低计算开销[7]，适用于嵌入式实时检测。

在分心行为识别方面，胡敏构建了时空注意力网络[8]，能同时捕捉手部动作与面部表情，实现对多种分心行为的准确识别；陈华基于骨架关键点的行为分析方法[9]，在保障隐私的同时提升了检测准确率。

关于多模态融合技术的发展，王国栋提出的视觉与红外双通道识别系统显著提升了夜间或光照不良环境下的行为监测能力[10]，在夜间驾驶场景中表现稳定，不易受干扰；刘肖提出融合车辆运行数据与驾驶员生理特征信号的方法[11]，并构建出一个多源信息融合框架，这种方法的优势是能够在突发状况发生前识别潜在风险，从而更早介入干预。可以看出，国内在该领域的研究呈现出多维度推进和实用化转化并重的趋势，部分成果在精度与性能上已具备与国际前沿研究比肩的实力。

1.2.3 研究现状小结

基于计算机视觉的驾驶员行为监测系统是人工智能与智能交通融合发展的重要方向，对于提升交通安全、预防事故发生具有重要意义。国外研究起步早、基础雄厚，已在多模态信息融合、深度学习模型设计、系统集成与工程化应用等方面取得广泛成果，形成较为成熟的技术体系。我国在该领域的研究虽起步相对较晚，但近些年呈现出迅猛的发展态势，特别是在算法轻量化设计、特定应用场景优化等关键技术方向取得了突破性成果。

当前研究的共同趋势是：向多模态融合方向发展，结合视觉、红外、生理信号等多源信息；注重算法的实时性和鲁棒性，以适应复杂多变的驾驶环境；加强与主动安全系统的深度融合，从单纯的监测预警向主动干预方向拓展。未来研究中，如何在保护隐私的前提下实现更加精确的驾驶员状态评估，如何处理个体差异性问题，以及如何实现系统在极端环境下的稳定运行，仍是该领域亟待解决的关键科学问题。

1.3 论文的主要工作

围绕驾驶员行为监测这一核心目标，本系统的主要工作是设计和实现一个基于计算机视觉的的驾驶员行为监测系统，具体工作包括以下几个方面：

（1）疲劳行为检测：设计基于 Dlib 的人脸特征点检测算法，通过对驾驶员面部区域定位、提取面部特征和计算头部姿态角，并分析眼部、嘴部和头部三个部位的特征，结合相应的阈值，完成对驾驶员疲劳状态的判定。

（2）分心行为检测：利用优化后的 YOLO 目标检测模型，识别水杯、香烟、手机等目标物体，进而有效监测驾驶员喝水、抽烟等分心行为。

（3）用户界面设计：通过 PySide6 构建系统的用户界面，实现了图片、视频及获

取摄像头，将检测到的行为状态结果呈现给用户，实现了人机交互。

1.4 章节安排

全文共分为五章，具体结构安排如下：

第一章为绪论，阐述研究背景与意义，分析国内外相关研究现状，介绍论文的主要工作内容及章节安排。

第二章为相关技术背景，主要介绍本系统所涉及的关键技术，包括 Dlib、YOLO 目标检测算法等内容，为后续系统设计与实现提供理论支持。

第三章为驾驶员行为监测系统设计，围绕系统架构，详细说明各功能模块的设计思路与实现方法，包括系统界面的设计与实现。

第四章为训练与分析，介绍了实验的整体流程，包括前期准备（数据集的一系列处理等）、训练过程以及结果总结和分析，通过实验验证了系统的有效性。

第五章为总结与展望，对全文的工作进行了总结，分析存在的不足，并对未来研究的方向进行思考和展望。

2 相关技术背景

2.1 Dlib 简介

Dlib 是一个高效、开源的 C++跨平台工具库，广泛应用于机器学习、计算机视觉和数据分析等领域，其提供了人脸检测、人脸识别、姿态估计、图像分类、图像分割等多种功能[12]；采用了先进的算法和数据结构，并且提供了简单易用的接口，便于开发者快速上手，具备很好的可扩展性。

Dlib 因其稳定性、易用性和高效性，在学术界和工业界均有广泛应用，是计算机视觉领域的重要工具之一。

2.2 目标检测算法 YOLO

YOLO（You Only Look Once）是一种广泛应用于目标检测任务的深度学习算法，其主要思想是将目标检测问题转化为一个回归问题，通过一次前向传播便可同时完成图像中目标的位置定位与类别识别任务[13]。

该算法的具体过程是，将输入图像划分为 S×S 的等大小网格，每个网格负责检测其内部中心点是否被目标占据；对于每个网格，YOLO 会产生一些边界框的预测结果，同时给出每个边界框对应的置信度和对应的类别概率，这里所说的置信度是指边界框中是否是目标的可能性，它也反映了预测边界框和实际边界框的重叠度，即 IOU

（Intersection over Union）[14]。最后，YOLO 模型输出的结果是具有边界框坐标信息、置信度值和对应类别概率的张量，用以完成图像所有目标的检测任务。

（1）边界框（Bounding Box）

YOLO 目标检测模型网络预测的每个检测框的空间位置，即预测输出边界框的中心点坐标（x,y）以及检测框的宽高 w、高 h 两个尺寸参数，共同决定了目标在图像中的空间位置。

（2）置信度（Confidence Score）

置信度是 YOLO 中预测结果可靠性的评估指标，通过预先计算预测结果是否为真实物体的部分，可以得出置信度。计算这个置信度的关键在于判断框是否有“有效物体”，即判断框内是否有真实的物体或边界框与真实物体的匹配程度。匹配程度通常用 IOU 来表示，即预测框和真实框之间的重叠情况。置信度的计算公式如下：

$$\text{Confidence} = P(\text{Object}) \times \text{IOU}_{\text{pred}}^{\text{true}} \tag{2.1}$$

其中，P(Object)是网格单元包含目标的概率，$\text{IOU}_{\text{pred}}^{\text{true}}$是预测框和真实框的交并比。

（3）类别预测

除了边界框本身的定位，YOLO 还会对每个边界框进行类别判断，输出一个概率分布，这些概率值量化了目标与各类别的匹配置信度。这部分预测是基于已知该区域包含目标的前提下进行的条件概率预测，即：$P(C_i \mid \text{Object})$，$C_i$表示第 i 个类别。

整体来看，YOLO 模型采用的是一种端到端的训练方式，即直接从图像像素出发，通过单次前向传播即可输出目标的位置与类别。凭借其卓越的检测速率和优异的响应性能，该算法在需要实时处理的场景中展现出显著的应用价值。

2.3 注意力机制

注意力机制是一种受到人类视觉系统启发的计算方法，其核心思想是使模型在处理输入数据时能够自动聚焦于更为关键的信息区域，从而提升特征提取的有效性以及整体识别精度。在 YOLO 目标检测框架中，合理引入注意力机制，有助于模型在复杂的背景或多目标场景中，更准确地进行目标的识别与定位。

2.3.1 SE 注意力机制

SE 注意力机制通过自主学习特征通道的重要性分布，来增强有用信息并削弱无关特征，以此来提高网络的表达能力。其结构主要包含两个核心操作：Squeeze（压缩）和 Excitation（激励），如图 2.1 所示。

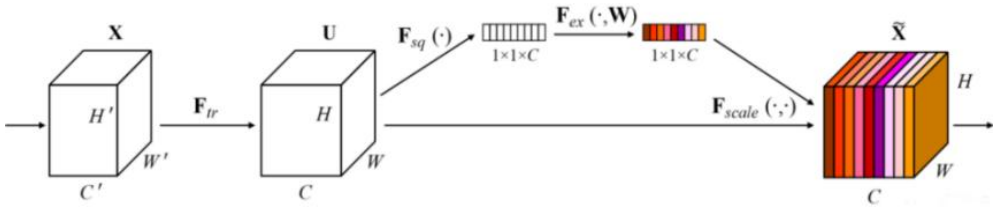

图 2.1 SE 注意力机制结构图

其中，特征压缩阶段，压缩操作利用全局平均池化方法，将原始的三维特征图在空间维度执行压缩处理，最终得到一个一维的通道描述向量，用以概括每一个通道的全局信息；在特征激励阶段，通过两层全连接的神经网络对所有的通道权重进行预测，并利用 Sigmoid 函数生成归一化后的权重系数，这些权重会被重新作用到原始的各通道特征图上，使得网络能够主动突出更具判别力的特征，同时抑制冗余或干扰信息。

将 SE 模块嵌入 YOLO 网络结构中，能够在不显著增加计算负担的前提下，提升模型对关键信息的感知能力，使检测结果更具稳定性和准确性，尤其适用于驾驶员行为识别等对细节感知要求较高的任务场景。

2.3.1 CBAM 注意力机制

CBAM 是一种结合了通道维度（Channel）和空间维度（Spatial）的注意力机制，结构如图 2.2 所示。它通过逐步引导模型注意“哪些特征重要”和“哪些位置关键”，从而进一步提升网络对目标区域的识别能力。

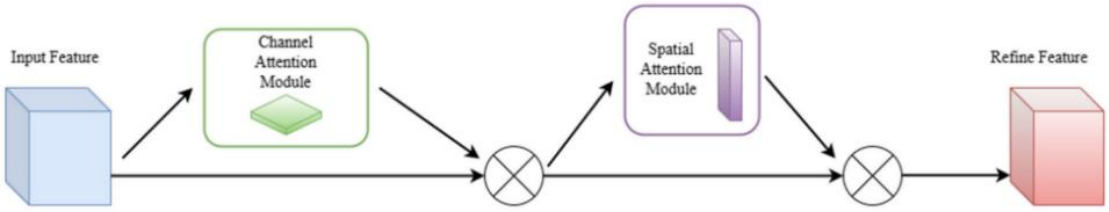

图 2.2 CBAM 注意力机制结构图

在通道注意力模块（Channel Attention Module）中，通过先使用全局平均池化和全局最大池化分别提取特征图通道维度上的不同统计信息，再将其输入到共享的全连接层处理，输出一组各通道的重要权重，使得模型自动对更有利于任务的通道进行加强处理；空间注意力模块（Spatial Attention Module）在通道加权后的特征图上，再次进行池化操作提取空间特征并且使用卷积核生成空间注意力图，使得模型聚焦于图像的关键区域，而不是在所有地方浪费注意力。

将 CBAM 嵌入到 YOLO 目标检测网络中，不会产生额外的计算压力，同时能够提高复杂背景下模型对有效特征的提取能力，尤其适合像驾驶员行为识别这类对细节关注度要求较高的任务场景。

3 驾驶员行为监测系统设计

3.1 系统总体设计

3.1.1 系统架构

驾驶员行为监测系统用模块化的设计思路，将复杂的系统功能拆解成多个模块，各个模块既分工明确又能配合工作。系统的总体架构如图 3.1 所示。

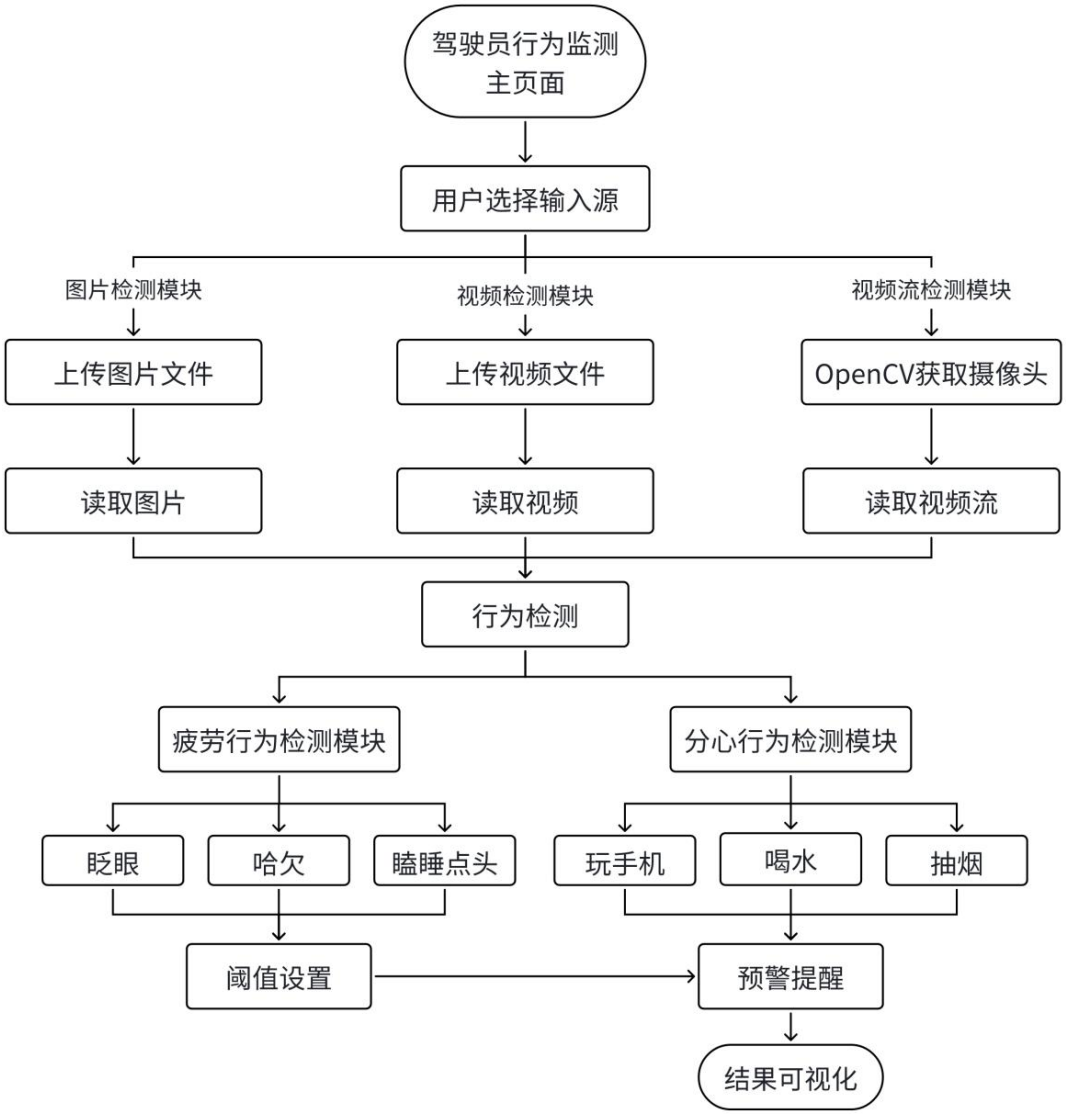

图 3.1 驾驶员行为监测系统架构图

系统主要由以下几个部分组成：

（1）此系统支持图片、视频及视频流三种类型的输入方式，用 Dlib 结合 YOLO 算法对输入的数据进行行为检测，即疲劳行为和分心行为的检测，最终都会传递给结果可视化模块进行展示，实现了友好的人机交互。

（2）疲劳行为检测模块，先使用 Dlib 的人脸检测器对图像数据进行扫描，快速定位出人脸区域；定位完成后，系统会基于预训练好的特征点模型，从人脸区域提取 68 个关键点，这些关键点能够准确地描述脸部轮廓、嘴巴、眼睛等主要区域的位置和形状。通过这些关键点，可以进一步分析驾驶员的疲劳行为，如眨眼、哈欠等，为后续的疲劳判断提供基础。

（3）分心行为检测模块，利用 YOLO 目标检测算法对输入的数据进行分析，定位水杯、香烟和手机等目标物体，可以有效识别驾驶员是否存在喝水等分心行为。

（4）阈值设置，主要是对检测到的疲劳行为进行进一步判断。当驾驶员表现出疲劳状态时，驾驶员会出现一些明显的生理反应，如频繁眨眼、点头打瞌睡等，对于这些变化，系统设定一些合理的判别标准，只要采集到的行为数据超过了这些设定值，系统就会认为驾驶员进入疲劳状态，并及时作出响应。

（5）预警提醒，在系统识别到驾驶员出现驾驶疲劳状态时，及时触发预警机制。预警方式包括在用户界面上弹出警告信息和发出声音报警，旨在让驾驶员及时意识到自己的状态不对，尽快调整，保障驾驶安全。

（6）结果可视化模块，总结了疲劳行为、分心行为检测、阈值的设置及预警提醒的结果，通过 PySide6 开发的用户界面，将可视化结果呈现给用户。

该系统采用模块化设计，支持图片、视频和视频流多种模态输入，通过 Dlib 库和 YOLO 算法进行行为检测，结合相应的阈值进行实时预警，最终通过 PySide6 开发的交互界面实现检测结果的可视化呈现。整体上，该系统在响应速度与交互性能方面表现出较高水准，是一套集成度强、功能完善的驾驶员行为监测系统。

3.1.2 主界面设计

系统的主界面是用户进入系统后的第一个页面，如图 3.2 所示，为了方便用户使用和直观展示驾驶员行为监测系统的检测结果，需要提供清晰、简洁的功能导航。

图 3.2 系统主界面

（1）系统标题：在界面顶部显示名称“驾驶员行为监测系统”，突出系统功能。

（2）图像显示区域：用于实时显示摄像头拍摄的驾驶员面部图像或经过处理后的检测结果图像，让用户能够直观地看到驾驶员的当前状态。

（3）状态信息显示区域：在该区域展示驾驶员的各种状态信息，这些信息以直观清晰、便于理解的形式呈现给用户，方便及时了解驾驶员的行为情况。

（4）参数设置区域：提供一些可调节的参数设置选项，供用户根据自身需求对参数进行设置，以满足不同的行驶场景和监测要求。

（5）警告提示区域：当系统检测到了驾驶员存在疲劳驾驶时，会以显著方式发出警告提示信息，例如文字提醒或警告弹窗，并辅以声音报警，以增强提醒效果。从而促使驾驶员及时纠正不良驾驶状态，降低潜在风险。

（6）主界面的配色以简约、友好为主，采用让人感觉舒适的色调。界面布局简单大方，体现出系统的简洁性和易用性。

3.2 疲劳行为检测模块

疲劳行为检测是驾驶员行为监测系统的核心功能之一，主要识别眨眼、哈欠及点头瞌睡的行为任务。本小节将详细介绍该系统疲劳行为检测模块的设计与实现。

3.2.1 疲劳行为检测流程

疲劳行为检测的整体流程如图 3.3 所示。

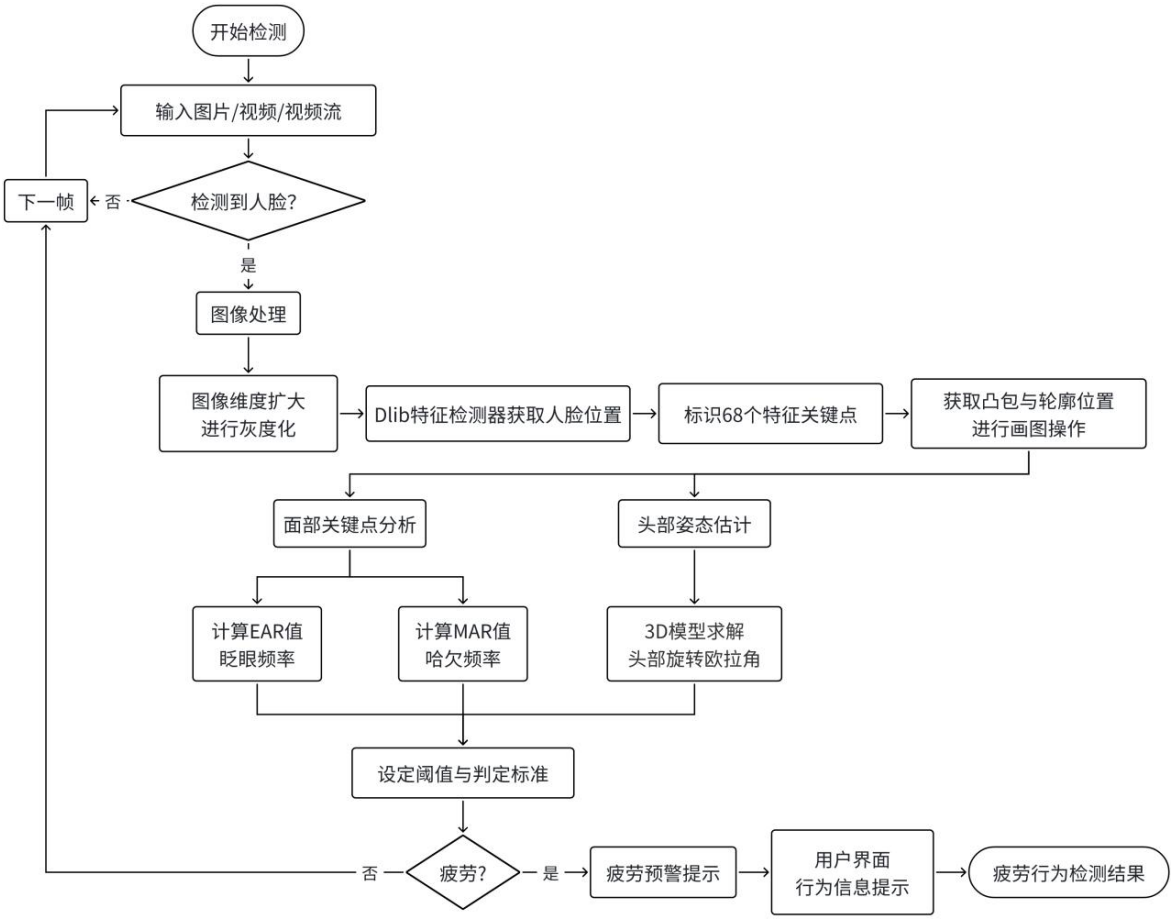

图 3.3 疲劳行为检测流程

具体步骤如下：

（1）人脸位置检测

从图片、视频及摄像头中获取人脸图像，使用 Dlib 的 HOG 特征检测器对输入的数据进行扫描，快速定位出图像中的面部区域，一次性可以检测多个人脸，并通过预训练的 68 点模型识别面部特征点，输出为在已定位的面部区域内提取出 68 个关键的人脸特征点，如图 3.4 所示。

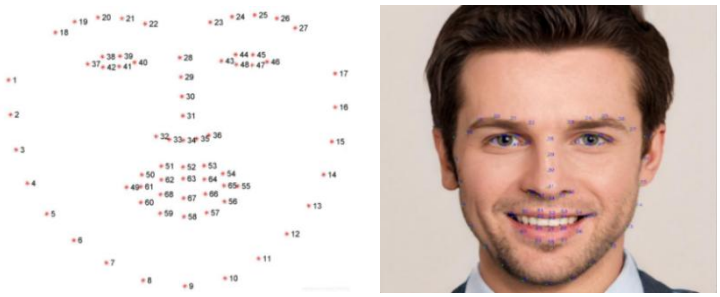

（a）68 个人脸特征点模型 （b）面部特征点分布

图 3.4 人脸特征点

（2）面部关键点分析

在完成面部区域识别的前提下，系统进一步提取左眼、右眼及嘴部的关键特征点，并分别计算 EAR 与 MAR。当检测到 EAR 连续低于预设阈值时，系统会将该状态计为一次眨眼行为。通过统计眨眼的频率与持续时间，系统可综合判断用户是否存在疲劳倾向。同时，系统依据 MAR 值判定嘴巴的张开状态，若连续三帧图像中 MAR 均高于设定阈值，则判断为一次打哈欠行为，并对其频次进行记录，用于进一步评估驾驶员的疲劳程度。

（3）头部姿态估计

运用 solvePnP（Perspective-n-Point）算法对驾驶员的头部姿态（俯仰角、偏航角和翻滚角）进行实时求解，在获取的姿态角度信息的基础上进一步判断驾驶员是否存在异常行为，如疲劳状态下经常会出现点头打瞌睡现象，此判断可作为疲劳状态识别的辅助判断，使系统能够在判断驾驶员状态时更加有据可依，更加精准。

（4）输出结果

根据设定的阈值和帧数连续性来判断疲劳状态，并输出报警及行为信息提示。

3.2.2 疲劳行为检测算法

疲劳行为检测算法的核心是基于 Dlib 的 68 个人脸关键点模型，结合 OpenCV 进行图像处理。模型使用这些关键点来计算眼睛纵横比（EAR）、嘴巴纵横比（MAR）和头部姿态角度（pitch、yaw、roll）。通过检测连续的帧来判断用户是否疲劳，特别是通过眨眼频率、打哈欠频率和瞌睡点头的行为判断疲劳状态

（1）眼睛纵横比 EAR

眼部特征是判断驾驶员是否疲劳的重要指标，提取人脸关键点位置后，主要选取眼部作为主要特征，计算 EAR 来判断是否发生眨眼行为。EAR 值是根据眼部关键点

之间的垂直和水平距离得出的。正常睁眼时，EAR 的值会维持在一个比较稳定的区间；当眼睛闭合时，EAR 会迅速下降，理论上甚至接近于零，受到人脸检测精度的限制，实际计算出来的值通常会比零稍高。

系统通过设置合适EAR阈值，当检测到 EAR 持续低于该阈值时，即可判断眼睛处于闭合状态[15]；进一步地，当EAR值由正常水平迅速下降至阈值以下，再快速回升至阈值以上时，即可视为一次完整的眨眼行为。为确保眨眼识别的准确性，还需设定同一次眨眼对应的连续帧数限制，考虑到眨眼通常在 1 至 3 帧内完成，因此系统在此范围内进行眨眼计数。当驾驶员处于疲劳状态时，其眨眼频率通常会增加，或单次眨眼持续时间延长，故通过EAR变化规律可初步判断是否存在疲劳迹象。实现方法如下：

首先从 68 个关键点中按序号提取出眼部特征点坐标，左眼特征点序号为 37-42，右眼特征点序号为 43-48，如图 3.5 所示。相关计算公式如下所示：

左眼 EAR 值的计算公式如下所示：

$$EAR_{left}=\frac{\| P_{38}-P_{42} \|+\| P_{39}-P_{41} \|}{2\| P_{37}-P_{40} \|} \tag{3.1}$$

右眼 EAR 值的计算公式如下所示：

$$EAR_{right}=\frac{\| P_{44}-P_{48} \|+\| P_{45}-P_{47} \|}{2\| P_{43}-P_{46} \|} \tag{3.2}$$

其中，P_n(n=37, 38, ..., 48)代表序号为 n 的眼部关键点坐标；EAR_{left}为左眼 EAR 值，EAR_{right}为右眼 EAR 值。

最终 EAR 的值取两者的平均，计算公式如下所示：

$$EAR = \frac{EAR_{left}+EAR_{right}}{2} \tag{3.3}$$

其中，EAR_{left}为上式（3.1）计算的左眼 EAR 值，EAR_{right}为上式（3.2）计算的右眼 EAR 值。

睁眼和闭眼状态下关键点的分布情况如图 3.5 所示，从图中可以看出，眼部的开合角度在不同状态下存在差异，且相应的 EAR 值也有明显变化。

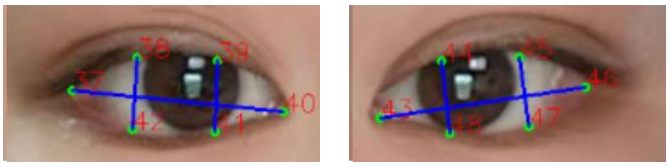

(a) 左眼关键点 (b) 右眼关键点

图 3.5 眼部特征点

眨眼过程中的 EAR 值变化曲线如图 3.6 所示。由图得，处于睁眼状态时，EAR 值在某一固定值附近略微波动；而在眨眼的过程中，EAR 值会迅速下降，随即瞬间恢复到睁眼时的固定值附近[16]。EAR 值的变化趋势清晰地反映出眨眼动作的发生，闭眼状态下眼睛的纵横比明显小于睁眼状态时的纵横比，所以 EAR 值的变化可作为判定疲劳状态的重要指标。

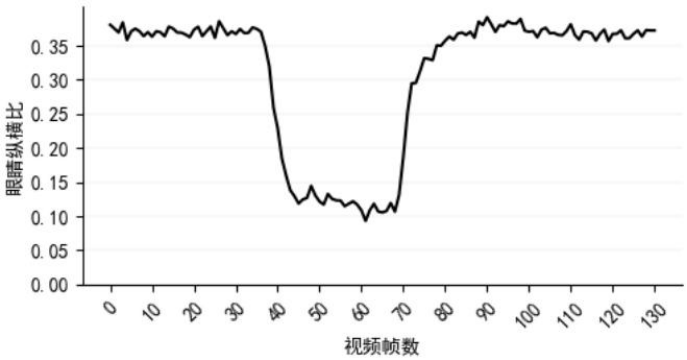

图 3.6 眨眼状态的眼睛纵横比变化曲线图

（2）嘴巴纵横比 MAR

在疲劳检测过程中，嘴部特征的重要性不容忽视，它与眼部特征一样，能够为判断驾驶员是否疲劳提供关键信息。通过分析嘴部周围的关键点，可以计算出嘴巴的纵横比（MAR），从而监测嘴巴的开合程度。在疲劳驾驶的情况下，驾驶员打哈欠的频率会明显增多，导致嘴巴的张开程度发生显著变化。通过计算嘴部特征点的坐标信息，可以得出 MAR 值，并设定相应的阈值。当 MAR 值超过预设阈值时，便可认为驾驶员处于疲劳驾驶状态；同时考虑驾驶员在驾驶过程中可能会因说话而产生张开嘴巴的行为，将嘴巴状态分为闭嘴、说话以及打哈欠状态[17]，三种状态如图 3.7 所示。经仔细测试发现在说话状态下嘴巴的开合程度较小且时间较短，而打哈欠时嘴巴开合程度较大且时间较长。

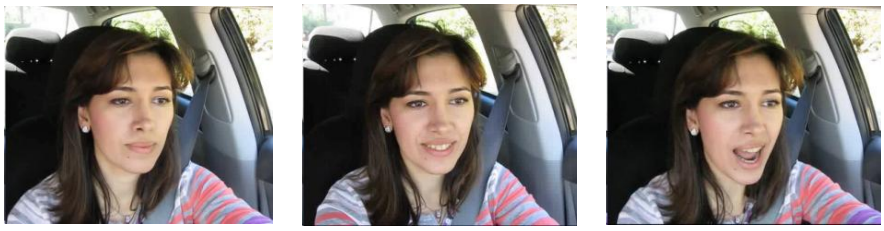

（a）闭嘴状态 （b）说话状态 （c）打哈欠状态

图 3.7 三种状态下的嘴巴开合程度

MAR 的计算，当嘴巴正常闭合时，MAR 值会在一个比较小的范围内轻微波动，但嘴巴张开时，MAR 值会明显升高，实际检测过程中难以精确捕捉到嘴巴完全闭合或完全张开的那一瞬间，所以我们会设定一个阈值，当 MAR 值超过这个阈值时，判断嘴巴处于张开状态。当 MAR 值从一个相对稳定的值突然升高并超过该阈值，且持续了一段时间，然后又下降至小于该阈值时，便可判定为打了一次哈欠。考虑到打哈欠速度相较于眨眼稍慢，打哈欠一般在 3 至 5 秒内完成，为了避免误判，需要设定同一次开合动作的连续帧数。

根据关键点检测结果，可以得出表示嘴部轮廓的关键点共有 20 个，外嘴唇主要特征点如图 3.8 所示。

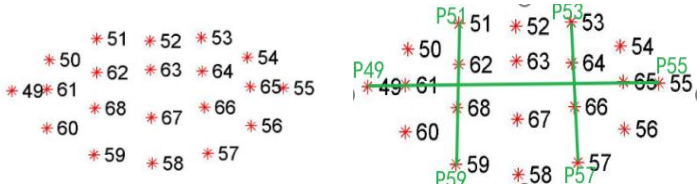

（a）嘴部特征点图 （b）选取坐标点图

图 3.8 嘴部特征点示意图

参考基于眼部特征的疲劳检测方法中的眼睛纵横比，我们将嘴巴的开合角度定义为嘴部的纵横比。MAR 值的计算公式如下所示：

$$MAR=\frac{\| P_{51} - P_{59} \| + \| P_{53} - P_{57} \|}{2\| P_{49}-P_{55} \|} \tag{3.4}$$

其中，P_{51}、P_{59}、P_{53}、P_{57}、 P_{49}、P_{55}分别代表嘴部特征点坐标在嘴巴上从左嘴角开始按顺时针分布的外嘴唇主要特征点坐标。

从上面的分析可以看出，嘴部在不同状态下的开合程度差异还是很明显的，对应的 MAR（嘴部纵横比）也会呈现出截然不同的变化趋势。一段时间内嘴部处于三种状态时的 MAR 值变化曲线如图 3.9 所示，黑色代表闭嘴时的 MAR，绿色代表说话状态，红色代表打哈欠。可以看出，在闭嘴状态下，MAR 值基本保持不变，几乎没有波动；在说话状态下，MAR 值会在 0.4 到 0.65 之间来回波动，但整体幅度不算太大；在打哈欠时状态下，MAR 值先是在一定范围内波动，接着突然升高到一个峰值，再下降到正常水平[18]。这些变化趋势中可以发现，打哈欠时嘴部的纵横比明显高于另外两种状态。也正是因为这种差异足够明显，MAR 的波动情况就可以拿来作为一个判断疲劳状态的有效指标。

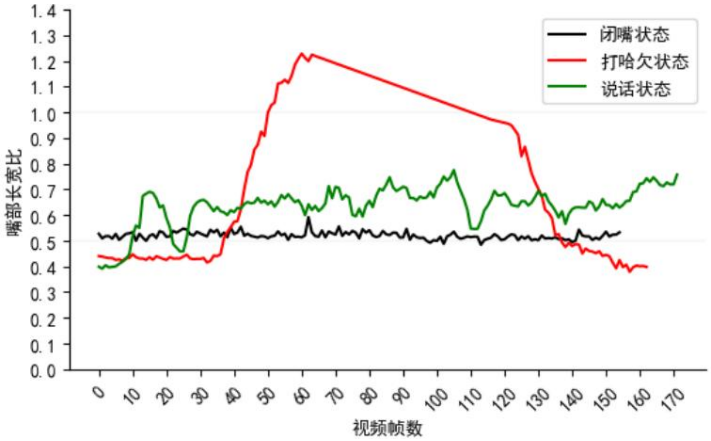

图 3.9 不同状态的嘴部长宽比变化曲线图

（3）头部姿态估计算法

驾驶员的头部姿态可以很好的反应驾驶员的疲劳状态，当驾驶员在正常驾驶车辆的过程中，头部姿态处于相对稳定的状态，驾驶员在驾驶车辆行驶的过程中，头部会随着驾驶环境进行适当的转动对周围环境进行观察；当驾驶员产生疲劳状态时，此时头部姿态会发生一定的变化，出现低头、点头瞌睡等姿态变化，将这种变化和头部姿态估计技术结合在一起，通过计算头部的欧拉角，结合欧拉角的正负来判断驾驶员是否处于疲劳状态。

根据头部姿态计算的原理，可利用图像信息来获取头部姿态角。在三维空间中，物体的旋转通常由三个欧拉角（Euler Angle）表示：pitch（围绕 X 轴旋转）、yaw（围绕 Y 轴旋转）和 roll（围绕 Z 轴旋转），如图 3.10 所示，这三个角度分别对应于俯仰角、偏航角和滚转角，通俗地说就是头部的抬头、摇头和转头动作。

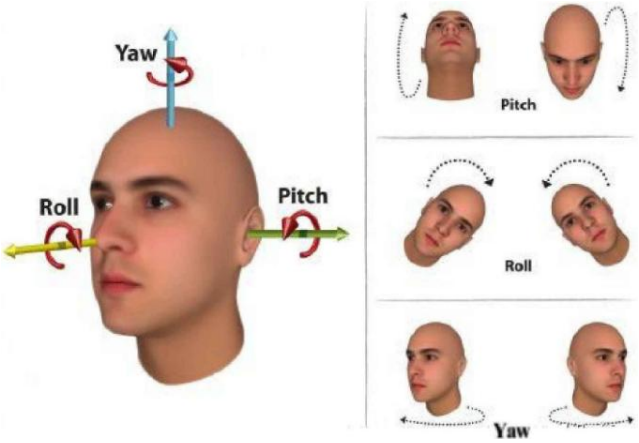

图 3.10 头部欧拉角示意图

为实现头部姿态估计算法，其一般步骤如图 3.11 所示，通过提取人脸特征点坐标信息进行几何变化和运算；结合相机成像原理对头部的垂直方向俯仰角度确定，通过特征点分析和计算实现头部的姿态估计，对判断疲劳提供依据。其运算过程综合考虑人脸特征点在图像平面的位置关系以及相机内参和外参等参数进行运算，对头部的俯仰角度进行准确定位，从而对司机疲劳状态进行进一步的细分识别，如当头部俯仰角超过正常范围并持续一段时间，可以判定为疲劳驾驶。

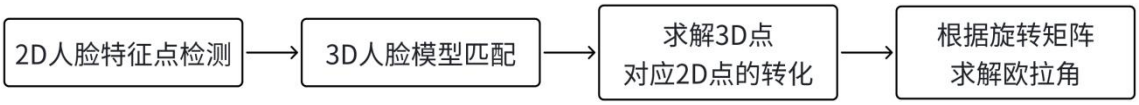

图 3.11 头部姿态估计算法步骤

一个物体相对于相机而言的姿态，可以用旋转（R）和平移（T）矩阵来表示，这需要进行坐标系变换，其原理如图 3.12 所示。在头部姿态估计中，涉及到多个坐标系的转换，包括世界坐标系（UVW）、相机坐标系（XYZ）、图像中心坐标系（uv）和像素坐标系（xy），借助这些坐标系的转换，将三维空间的坐标转换为二维图像中的坐标，进而实现对头部姿态的估计[19]。

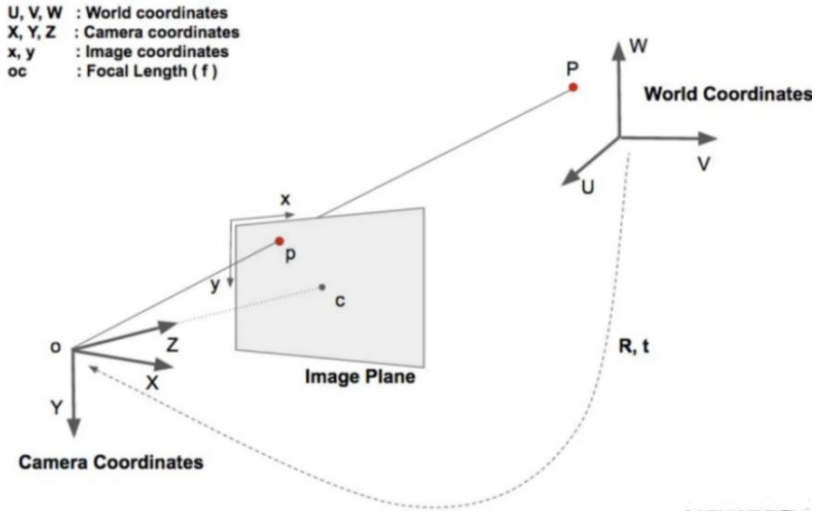

图 3.12 坐标系转化原理

3D 人脸模型与对应 2D 特征点的映射，需要经过三大坐标系的转换，该过程涉及世界坐标系、相机坐标系（均为三维空间）到图像坐标系（二维平面）的变换。通过 Dlib 库对人脸特征点进行提取，可获得各关键点在二维图像中的坐标信息。相机的内

部参数、焦距和焦点可以由系统得出，所以三大坐标系之间的转化只需经过旋转矩阵和平移矩阵的变化[20]。以下是三大坐标系转化的详细公式如下所示：

① 世界坐标系到相机坐标系，转换关系如下所示：

$$\begin{bmatrix} X \\ Y \\ Z \end{bmatrix} = R \begin{bmatrix} U \\ V \\ W \end{bmatrix} + T = [R|T] \begin{bmatrix} U \\ V \\ W \\ 1 \end{bmatrix} \tag{3.5}$$

② 相机坐标系到像素坐标系，转换关系如下所示：

$$s \begin{bmatrix} X \\ Y \\ Z \end{bmatrix} = \begin{bmatrix} f_x & 0 & c_x \\ 0 & f_y & c_y \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} X \\ Y \\ Z \end{bmatrix} \tag{3.6}$$

③ 像素坐标系和世界坐标系的关系如下所示：

$$s \begin{bmatrix} X \\ Y \\ Z \end{bmatrix} = \begin{bmatrix} f_x & 0 & c_x \\ 0 & f_y & c_y \\ 0 & 0 & 1 \end{bmatrix} [R|T] \begin{bmatrix} U \\ V \\ W \\ 1 \end{bmatrix} \tag{3.7}$$

其中f_x、f_y、c_x、c_y为相机标定参数。

如果相机存在一些瑕疵，比如切向或径向畸变，那么坐标转换的过程就会变得相对复杂，这需要先将相机坐标系转换到以图像中心为原点的坐标系，然后再从图像中心坐标系转换到像素坐标系。相关公式如下所示：

$$s \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} f_x & 0 & c_x \\ 0 & f_y & c_y \end{bmatrix} \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} \tag{3.8}$$

上式中世界坐标系的坐标为 (u,v,w)，相机坐标系中的坐标为 (x,y,z)，根据这两个坐标系的信息可以确定其在空间的方位，经过线性的变化得到转化公式（3.8），即可得出旋转矩阵。相关公式如下所示：

$$\begin{aligned} R_x(\theta) &= \begin{bmatrix} 1 & 0 & 0 \\ 0 & \cos\theta & -\sin\theta \\ 0 & \sin\theta & \cos\theta \end{bmatrix} \\ R_y(\theta) &= \begin{bmatrix} \cos\theta & 0 & \sin\theta \\ 0 & 1 & 0 \\ -\sin\theta & 0 & \cos\theta \end{bmatrix} \\ R_z(\theta) &= \begin{bmatrix} \cos\theta & -\sin\theta & 0 \\ \sin\theta & \cos\theta & 0 \\ 0 & 0 & 1 \end{bmatrix} \end{aligned} \tag{3.9}$$

即可求解出我们需要的欧拉角：

$$\begin{cases} \varphi = a\tan(-r_{12}, r_{22}) \\ \emptyset = a\tan(r_{02}, \sqrt{r_{12}^2 + r_{22}^2}) \\ \gamma = a\tan(-r_{01}, r_{00}) \end{cases} \tag{3.10}$$

其中，φ、$\emptyset$、γ分别表示头部围绕 X，Y，Z 轴旋转得到的角度，也叫俯仰角、偏航叫和滚转角，即欧拉角。

正常驾驶和低头状态下的欧拉角值如图 3.13 所示，从结果可以看出，在不同头部姿态下，欧拉角存在明显差异。

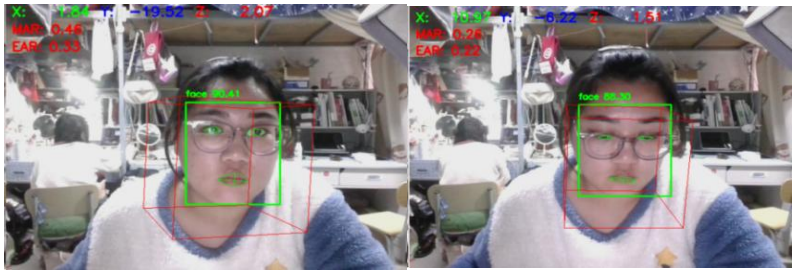

(a) 正常状态 (b) 低头状态

图 3.13 不同状态下的欧拉角

一段时间内处于两种不同状态的头部 pitch 值变化曲线如图 3.14 所示，由图得出，正常驾驶状态时，头部姿态处于稳定状态，pitch 值曲线较为平稳；在疲劳驾驶状态下，头部可能会出现低头打瞌睡的动作，这时头部下垂严重，pitch 值会大幅增加，直到驾驶员抬起头为止。低头状态的头部俯仰角相较于正常状态的俯仰角要大，所以 pitch 值的变化可以作为疲劳状态判断的参数。

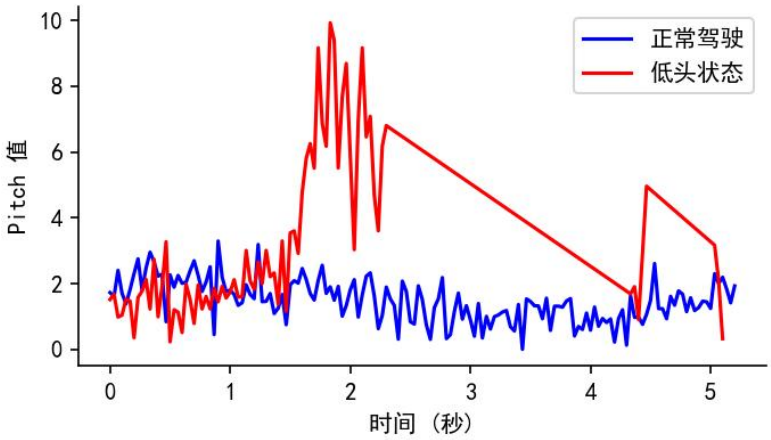

图 3.14 不同状态下头部 pitch 值的变化

3.2.3 疲劳判定标准

（1）眼睛闭合时间百分比 PERCLOS

PERCLOS（Percentage of Eye Closure）是比较常用且可靠的一个基于眼睛的疲劳指标。根据驾驶员在一段时间内眼睛闭上的时间比例来判定“眼睛”的疲劳状况，即眼睛闭合时间所占的比例，比例越大表明眼睛闭上的时间越长，也就越疲劳。计算公式如下：

$$PERCLOS=\frac{t_3-t_2}{t_4-t_1}=\frac{n_e}{N_e} \tag{3.11}$$

其中，n_e表示在单位时间内闭眼的帧数，即t_3到t_2时间段内闭眼所占的帧数；N_e表示在总时间的帧数，即t_4到t_1时间段内图像的总帧数。

在本实验中，PERCLOS 的阈值设为 0.38。一旦超过该阈值时，系统就会认定驾驶员已经处于驾驶疲劳状态。具体实验中，将 150 帧图像作为一个检测周期进行统计分析。当某一检测周期内的 PERCLOS 值大于 0.38 时，说明驾驶员在该时间段内眼睛闭合时间占比较高，疲劳程度较大，可能存在疲劳驾驶的风险。

（2）眨眼频率 BF

眨眼频率也是判断驾驶员是否处于疲劳状态的重要指标之一。持续监测驾驶员的眨眼情况，统计单位时间内的眨眼次数，以得到眨眼频率 BF。正常情况下，驾驶员的眨眼频率保持在一个相对稳定的水平上，一般在 0.2s~0.4s 眨眼一次，眨眼频率在 15~20 次每分钟；在疲劳状态下，眨眼频率会发生明显变化。可设定一个合适的 BF 阈值，当实际眨眼频率超过正常范围时，可判定驾驶员正处于疲劳状态。计算公式如下：

$$F_e=\frac{n_E}{t}\times 100\% \tag{3.12}$$

其中，n_E表示驾驶员眨眼的图像帧数，当 EAR>0.25 时，表示驾驶员进行了一次眨眼行为； t 表示时间。在本实验中，将F_e的阈值设置为 20，当F_e值超过设定的阈值时即 20，将判定驾驶员处于疲劳状态。

（3）打哈欠频率 YF

与检测眨眼频率类似，打哈欠频率 YF 也是判断驾驶员疲劳程度的一个重要指标，实验发现打哈欠的过程会持续 4s 左右，为了将打哈欠与正常说话行为区分开，本系统通过检测驾驶员嘴巴开合的程度即 MAR，与打哈欠时间来进行判断，当采集到驾驶员处于打哈欠状态图像且打哈欠时间超过 2.5s 时则处于疲劳状态。计算公式如下：

$$F_m=\frac{n_M}{t}\times 100\% \tag{3.13}$$

其中，n_M表示驾驶员嘴巴张开的图像帧数，当 MAR>0.65 时，表示驾驶员进行了一次打哈欠行为，t 表示时间。在本系统中，将F_m的阈值设置为 3，当F_m值超过设定的阈值时即 20，将判定驾驶员处于疲劳状态。

（4）疲劳预警功能

当系统判定驾驶员存在驾驶异常情况时，及时触发预警机制。预警方式包括在用户界面上提示行为信息、弹出警告提示信息及发出声音报警等，提醒驾驶员注意自身行为，及时纠正不良驾驶习惯，保障驾驶安全。疲劳判定流程如图 3.15 所示。

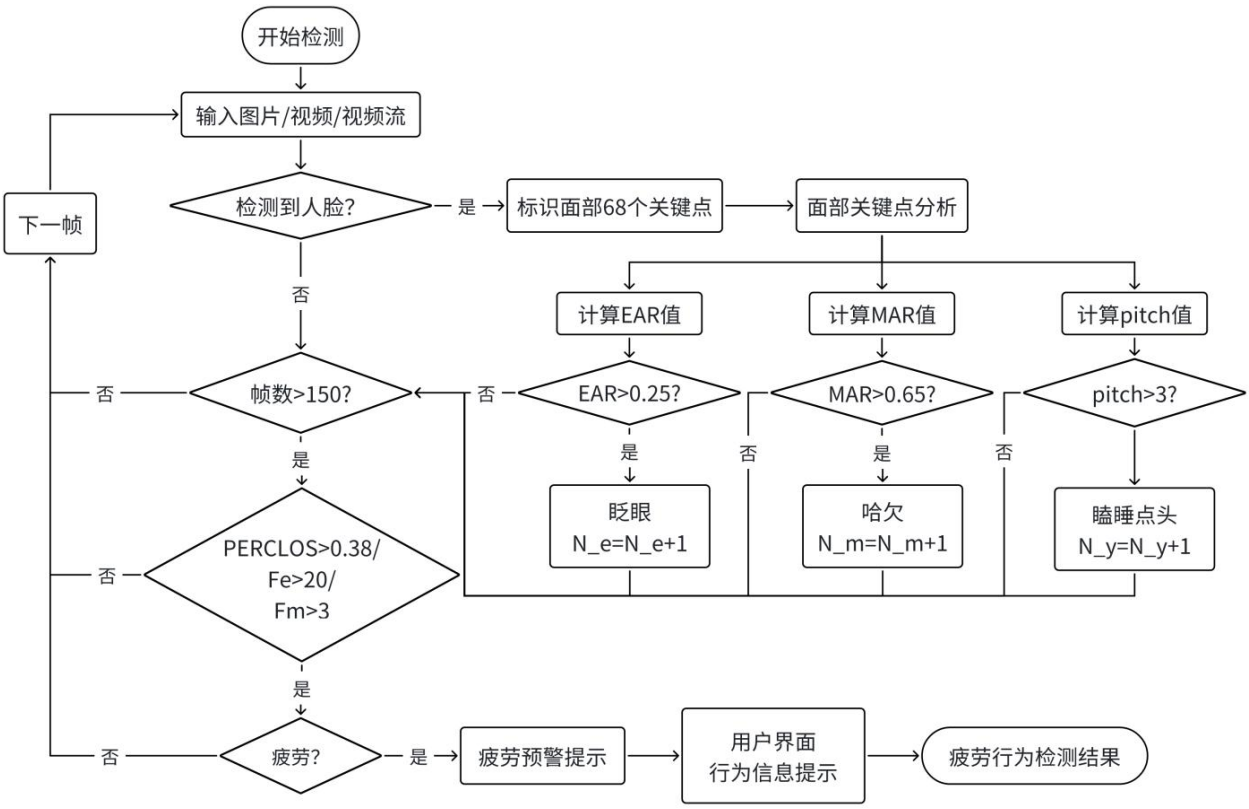

图 3.15 驾驶员疲劳状态判定流程

3.3 分心行为检测模块

分心行为检测是驾驶员行为监测系统的核心功能之一，主要识别玩手机、喝水及抽烟的行为任务。本小节详细介绍该系统分心行为检测模块的设计与实现。

3.3.1 分心行为检测流程

分心行为检测的整体流程如图 3.16 所示。

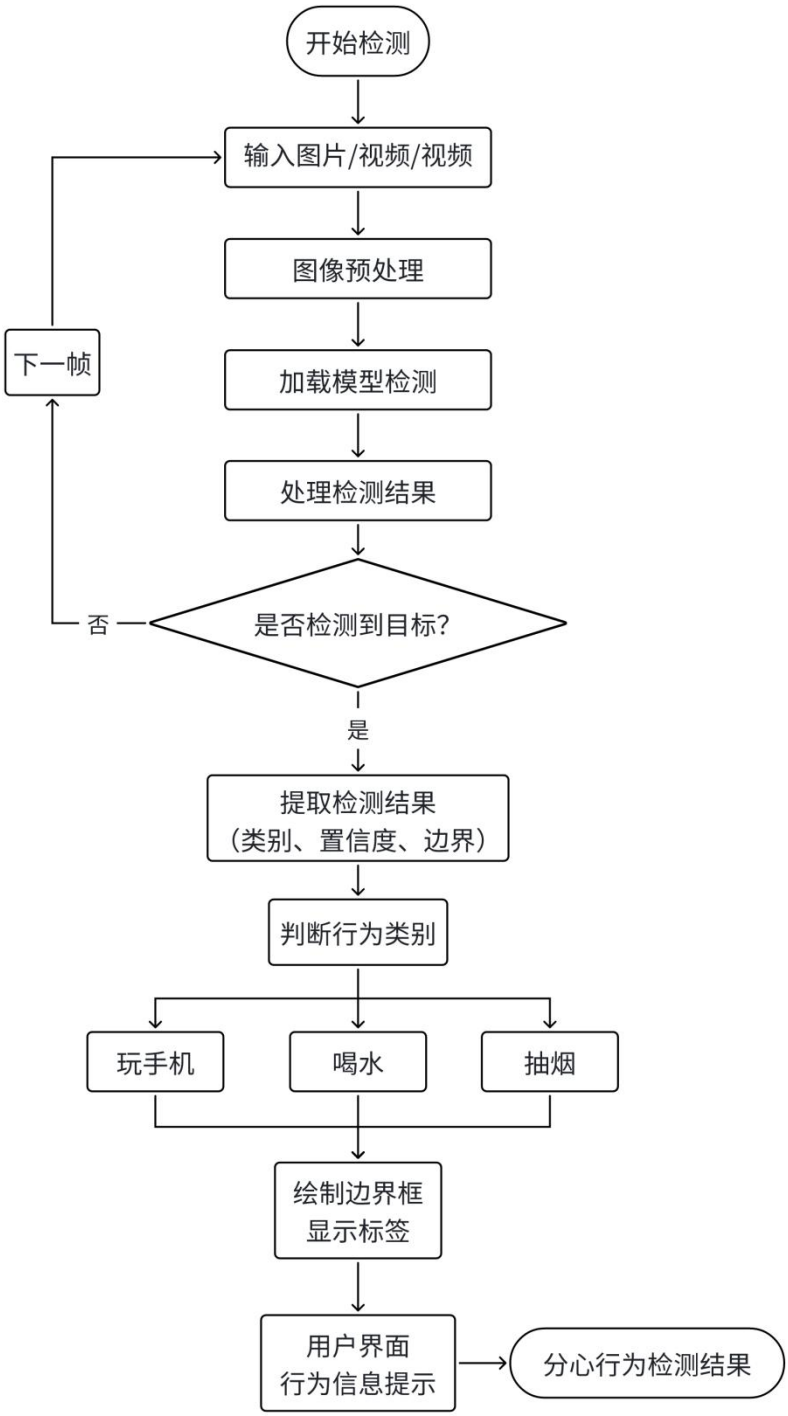

图 3.16 分心行为检测流程图

具体步骤如下：

（1）目标位置检测

① 图像获取与预处理

从图片、视频及视频流中按帧获取图像数据，对输入的图像数据执行预处理操作。预处理包括调整图像大小，使其符合模型输入要求；转换颜色通道，将图像从常见的

BGR 格式转换为模型所需的格式；归一化处理，将图像像素值映射到特定区间，以提升模型训练和推理的效果。

② 模型推理与结果处理

将图像数据输入至模型中进行推理，模型会对图像中的目标进行检测定位，在检测过程中会存在多个重叠的检测框，这就需要进行非极大值（NMS）抑制来筛选出最优的检测框。处理完成后，对检测结果进行遍历，将每个检测框的类别、置信度、坐标信息存储于一个列表中并返回，为后续处理提供数据支撑。

（2）结果可视化

得到检测的结果之后，还需要将检测到的行为以画面的形式呈现，把每一帧行为识别的位置用边界框框出，同时标注出该行为的行为类型和置信度。这样，用户可以直接通过图像画面看到有哪些分心行为及具体发生在哪个位置。可视化结果不仅有利于向用户展示识别结果，也为后续的行为分析与判断提供了一个清晰直观的参考依据。

（3）更新 UI 显示

将绘制了边界框和标签的图像实时更新至用户界面，让用户可以第一时间看到检测结果；同时在界面下方设置的提示区域，会同步显示所检测到的行为，如“检测到行为：smoke”之类的提醒。这些反馈能够及时提醒驾驶员，以便更快做出反应，对驾驶安全做出贡献，系统与用户之间形成良好的互动，增强了系统的功能性，也使体验更为流畅。

3.3.2 分心行为检测算法

本小节采用 YOLO 目标检测算法对驾驶员分心行为进行识别，主要检测对象包括喝水、抽烟以及使用手机这些典型的驾驶分心行为。本实验选用了在目标检测领域应用广泛的 YOLOv5s 模型作为核心框架，并在其基础上进行了一系列优化与调整，以提升检测的准确率和运行效率。

YOLOv5s 的网络结构主要由四大核心部分构成，分别是输入层（Input）、骨干网络（Backbone）、颈部网络（Neck）以及头部网络（Head）[21]；输入层主要负责接收原始图像并完成预处理操作，如尺寸调整、归一化等，以满足模型输入的要求；骨干网络通过一系列卷积层和池化操作提取图像的深层特征，生成特征图；颈部网络则对不同尺度的特征进行融合与优化，进一步提升模型对目标的感知与检测能力，常用结构包括特征金字塔网络（FPN）与路径聚合网络（PAN）；最终，头部网络基于融合后的特征图进行目标检测，输出目标类别及对应的边界框位置等信息。

在训练阶段，使用了大量的驾驶员分心行为图像，如玩手机、喝水、抽烟，为了能够使得模型对这些行为进行正确的识别，需对每张图像进行标注，标注出目标类别和目标位置；在训练阶段，系统将这些图像数据进行反复训练，通过反向传播，使得模型能够不断地学习，不断地提高参数，使得预测的结果和标注的值越来越匹配，最终使得模型能够正确的检测图像中是否存在分心行为，同时确认分心行为出现的具体位置，提高检测的正确率。

在推理阶段，图像数据输入到训练完成的模型中，模型会输出检测结果。需对这些结果进行非极大值抑制（NMS）处理，流程如表 3.1 所示，通过设定合适的阈值，去除那些重叠度较高且置信度较低的检测框，最终得到准确可靠的分心行为检测结果。

表 3.1 非极大值抑制处理流程（注：此表引自文献[22]）

非极大值抑制算法
输入 $B=\{(B_n,s_n)\}$，其中s_n是检测框B_n的得分，$D=\emptyset$；
步骤一：选择 B 中得分最大的预测框$\mathcal{M}$
步骤二：将$\mathcal{M}$以及得分添加到 D 中，在 B 中去掉$\mathcal{M}$和得分
步骤三：for B_i in B:
if $IoU(\mathcal{M}, B_i) \geq$ NMS_threshold
在 B 中去掉B_i以及得分；
End if
End for
步骤四：重复步骤 1~3，直至 B 为$\emptyset$

3.4 本章小结

本章围绕驾驶员行为监测系统展开，该系统采用模块化架构构建，整合了疲劳行为检测和分心行为检测两大核心功能模块。

（1）疲劳行为检测模块：该模块是系统核心之一。先借助 Dlib 的 HOG 特征检测器定位人脸区域，并利用预训练的 68 点模型提取关键特征点。通过这些特征点，计算 EAR、MAR 值和头部欧拉角，以此分析疲劳行为。同时，结合眼睛闭合时间百分比等上述判定标准，设定相应阈值，并综合考虑帧数的连续性来检测驾驶员是否存在疲劳行为，当判定为疲劳时系统将触发预警。

（2）分心行为检测模块：同样是系统的核心功能。本模块主要是通过采集、处理、注释和分割大量含有驾驶员分心行为(玩手机、抽烟等)的图片数据集，训练并测试 YOLO 模型。在实际运行时，按照每一帧为取图像数据，经过预处理后输入模型检测目标物，对预测结果进行非最大值抑制（NMS），最后将检测结果可视化到用户界面，实现对分心行为的识别。

系统通过 PySide6 开发了友好、直观的用户界面，支持图片、视频和视频流三种输入方式，并提供了参数设置、状态显示和预警提醒功能。结果表明其能够准确识别疲劳和分心行为，并通过可视化界面实时反馈监测结果，具有响应速度快、用户交互友好等特点。

4 训练与分析

本章主要介绍本系统在驾驶员分心行为检测任务中的实验流程与实现细节，包括环境配置、数据准备、模型训练、评估及结果分析。整体实验流程如图 4.1 所示，分为数据准备阶段、模型训练阶段与结果预测阶段，各阶段具体内容如下。

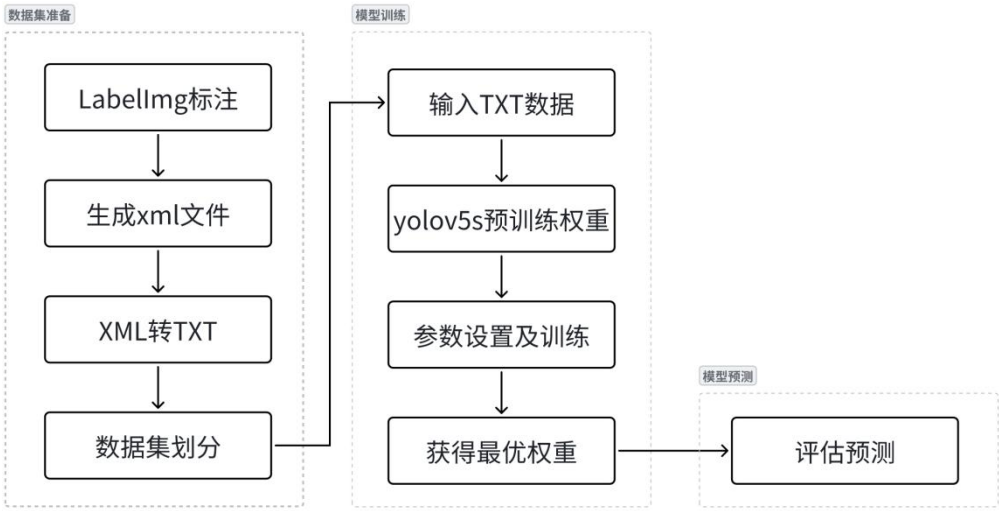

图 4.1 实验流程图

4.1 前期准备

4.1.1 环境准备

本实验利用 PyCharm 和 Anaconda 搭建前述基于 YOLOv5s 改进的模型 YOLO_S，并采用选取的数据集进行模型训练。实验环境配置如下表 4.1 所示。

表 4.1 实验环境配置

环境	版本号
搭建环境平台	Anaconda
开发环境	PyCharm 社区版
Python	3.8
Dlib	19.8.1

4.1.2 数据集

（1）数据集介绍

驾驶行为数据是识别和研究分心驾驶行为的重要基础。本实验收集并分析了现有的驾驶行为数据集，并列出了部分相关数据集的详细信息。

表 4.2 驾驶行为数据集

数据集名称	数据类别	采集人数	数据数量	分辨率	数据格式
StateFarm Dataset	10	81	102152	640×480	JPG
YawDD Dataset	3	-	351	1280×1080	AVI
AUC Distracted Driver Dataset	10	31	17308	1920×1080	JPG
SEU Driving Posture Dataset	4	20	-	640×480	JPG
Lilong Driving Behaviours	6	2648	267378	640×360	JPG/AVI

根据上表 4.2 中的数据集信息，发现仅有 StateFarm、YawDD 及 AUC 这三个数据集为公开数据，其他数据集都为研究者自建或私有，无法获取使用。从数据格式来看，现有的公开数据集大多以图片（JPG）形式存在，仅有 YawDD 数据集采用视频格式，但其所涉及的驾驶行为类别太少，仅有正常驾驶，打哈欠，与人交谈三种[23]。所以本实验基于已有公开数据集，并结合实际应用需求，构建了驾驶分心行为数据集。

（2）数据集的处理

① 对数据集进行标注

使用 LabelImg 对构建好的数据集进行标注，如图 4.2 所示，生成对应的 xml 文件，由于 YOLO 只接受 txt 的格式，需要将 xml 转换成 txt 的格式。

（a）驾驶员喝水行为标注

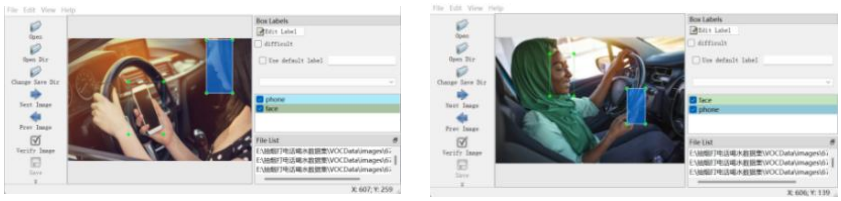

（b）驾驶员玩手机行为标注

图 4.2 数据集标注

② 数据增强（Data Augmentation）

数据增强是一种常见的训练策略，旨在通过对已有数据样本进行多样化处理，在不实际增加数据采集量的前提下，扩展训练集的规模与多样性。该技术通过对原始图像施加一系列变换操作，使模型能够学习到更具泛化能力的特征，进而提高其在复杂环境下的鲁棒性与准确率。它是克服训练数据不足的有效手段。

本实验使用 Albumentations 库实施了一系列的数据增强操作，如图 4.3 所示，如水平翻转、随机裁剪和旋转。这些操作用于模拟现实世界中的不同场景，例如不同的光照、视角和尺寸的变化。

（a）原始图像

（b）翻转图像

（c）裁剪图像

（d）旋转图像

图 4.3 数据集增强

（3）数据集的划分

为了构建稳健的模型，本实验构建的驾驶员行为数据集按 8:1:1 的比例分成训练集、测试集和验证集。这样的划分有助于全面评估该模型在不同的数据条件下的表现，并降低过拟合风险。

4.2 训练过程

4.2.1 训练模型

为验证不同规模的模型在驾驶员行为检测任务中的适应性与表现，本实验选取了 YOLOv5s 作为基础模型进行实验，具体步骤如下。

（1）数据准备：使用上述划分好的驾驶员行为数据集。

（2）训练参数设置：模型训练的主要参数设置如表 4.3 所示。

（3）训练过程：运行训练脚本开始训练模型，训练过程中通过验证集评估模型性能，自动保存性能最优的权重文件。

表 4.3 模型训练参数设置

超参数	值	超参数	值
Epoch	100	输入图像尺寸	640×640
BatchSize	16	Optimizer	Adam
LR	0.001	iou_t	0.2

4.2.2 评估模型

目标检测技术的核心在于准确识别目标类别，同时确保定位框能精准框选待识别的物体。当把目标检测的模型应用到检测分心驾驶行为领域时，不仅要考虑模型的推理速度（FPS）是否可以满足实际使用的需求，还需确保其精度能达到较高标准。

mAP，即类别的平均精度的均值，常用于目标检测效果的评估，是一个较为权威的指标。具体计算方式是以类别计算 AP 值（平均精度）对所有类别的 AP 值求平均，得到 mAP。而 AP 值的计算则需要以 Precision（精确率）和 Recall（召回率）这两个指标分别作为横纵坐标，在第一象限绘制出 P-R 曲线，通过计算该曲线所包围的面积来得出 AP 值，曲线下面积越大说明检测类的效果越好。相关计算如公式如下：

精确率计算如公式如下：

$$\text{Precision}=\frac{\text{TP}}{\text{TP+FP}} \tag{4.1}$$

召回率计算如公式如下：

$$\text{Recall}=\frac{\text{TP}}{\text{TP+FN}} \tag{4.2}$$

其中，四个衡量样本预测的指标含义如下：TP 代表真阳性，FP 为假阳性，TN 为真阴性，FN 为假阴性，其中 Precision 用于衡量模型的查准率，而 Recall 则是用来衡量模型的查全率[24]。

为验证不同规模的模型在驾驶员行为检测任务中的适应性与表现，本实验选取了 YOLOv5 的四个主流版本（v5n、v5s、v5m、v5l）进行横向对比实验。

表 4-4 各个模型对比实验结果

模型版本	推理速度（FPS）	mAP@0.5	Precision	Recall
YOLOv5n	36.51	0.824	0.855	0.78
YOLOv5s	18.43	0.888	0.898	0.856
YOLOv5m	8.903	0.814	0.868	0.727
YOLOv5l	4.488	0.846	0.826	0.802

从表 4.4 所展示的模型对比结果来看，YOLOv5 系列模型在驾驶员分心行为检测任务中的性能表现存在一定差异。

在检测精度方面，YOLOv5s 的 mAP@0.5 达到 0.888，明显高于其他版本，说明其在驾驶行为目标的准确识别上具有较强的能力。同时，其 Precision 和 Recall 分别为 0.898 和 0.856，表明模型在保持较高查准率的同时，也兼顾了较高的查全率，具有较强的整体检测可靠性。

在推理速度方面，YOLOv5n 拥有最高的推理速度，说明其在计算资源受限的情况下具有一定优势；但由于其 mAP 仅为 0.824，在检测准确性方面存在不足，限制了其在精度要求较高场景中的应用。YOLOv5l 的推理速度最低，仅为 4.488FPS，同时精度表现也不够突出，mAP 仅有 0.846，说明其在模型体量增加后未能换来成比例的性能提升。YOLOv5m 的推理速度为 8.903FPS，虽然较 YOLOv5l 更快，但精度与召回率均低于 YOLOv5s，未能展现出理想的速度和精度平衡。

综合评估结果表示，YOLOv5s 模型在本次测试中表现最为均衡，在保持较高推理速度（18.43FPS）的同时，实现了较高的检测精度，是后续进行模型改进的理想基础版本。

4.2.3 改进模型

基于对 YOLOv5 系列模型的评估，本实验选择了性能最均衡的 YOLOv5s 作为基础模型进行改进。根据第二章对注意力机制原理的介绍可知，适当引入注意力模块有助于引导模型关注更具判别性的特征区域，从而提升模型的收敛速度与检测精度。在 YOLO 系列权重模型中，集成注意力机制的过程包括以下步骤：

（1）选择合适的注意力模块：根据模型的需求选择合适的注意力模块，如 SE（Squeeze-and-Excitation）、CBAM（Convolutional Block Attention Module）等。

（2）集成注意力模块：将选定的注意力结构嵌入到 YOLO 模型的相应层中，通常需要对模型的配置文件和源码进行修改，以添加注意力模块的定义及其调用逻辑。

（3）调整模型结构：在添加了注意力模块后，可能需要调整模型结构，以确保数据流和层的连接正确无误。

（4）训练和验证：使用包含注意力机制的新模型结构进行训练，并通过实验验证模型在检测精度、召回率、收敛速度等指标上的变化情况。

本实验以 YOLOv5s 为基础模型，添加注意力机制，以提升驾驶员行为识别的准确性和性能。具体实现方式如下：在 Backbone（主干特征提取网络）末端嵌入 SE 模块，以增强特征通道的表达能力，同时在 Neck（特征融合网络）中的 C3 模块后引入 CBAM 模块，实现空间与通道信息的联合建模。这样一方面保持了原始特征提取结构的完整性，另一方面提升了模型对关键行为区域的关注能力。

经过评估本实验改进的模型 YOLO_S，在各项指标上整体表现优越，显示出良好的适应性和实用潜力，体现出引入注意力机制后带来的优化效果。

表 4.5 改进模型与基础模型的结果对比

模型版本	推理速度（FPS）	mAP@0.5	Precision	Recall
YOLO_S	20.76	0.954	0.964	0.93
YOLOv5s	18.43	0.888	0.898	0.856

从表 4.5 所展示的实验结果来看，YOLO_S 在保持 20.76 推理速度的前提下，同时实现了精度与稳定性的全面提升，说明模型在结构上进行了有效优化，提升了识别效果，保证了运行效率，具备较强的实用性。

综合来看，YOLO_S 在保持较高推理速度的同时，通过引入注意力机制显著提升

了模型的精度和稳定性。相较于原始的 YOLOv5s，改进后的 YOLO_S 模型在本次实验中表现最为突出，在实际部署中更具优势。其兼具准确性、实时性与部署灵活性，能够更好地满足驾驶员行为监测系统对检测质量与系统性能的综合需求。

4.3 训练结果与分析

结合前述训练流程及评估指标，对改进后的 YOLO_S 模型进行了实验验证。训练样本数据分布如图 4.4 所示，在绝大多数样本中均标注了“face”这一特征类别，因此该类目标在训练中具有较高的出现频率。受此影响，模型在检测人脸类别时的平均精度（AP）表现相对更优，能够获得更高的识别准确率。这说明模型在训练过程中对高频目标的特征学习更充分，从而提升了在人脸检测任务上的性能表现。

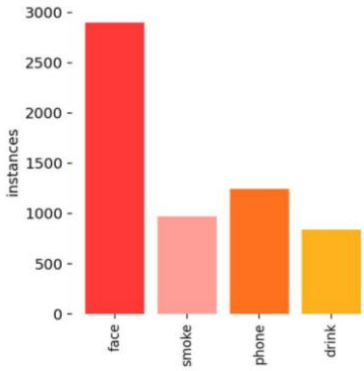

图 4.4 检测样本类别分布

本实验通过合理的模型调参策略对 YOLO_S 模型进行了优化，并把训练迭代的轮数设置为 100。在经过十余小时的训练后，模型逐渐趋于收敛状态。图 4.5 展示了模型在训练集与验证集上的三类关键损失项——预测框定位损失（Box）、置信度损失（Objectness）以及分类损失（Classification）的变化趋势。

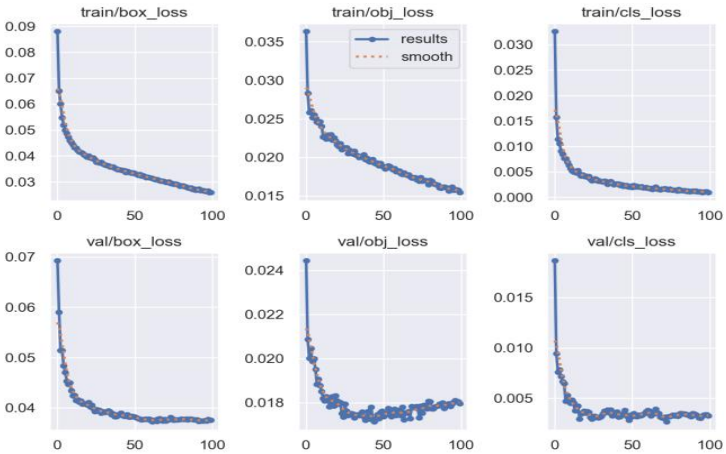

图 4.5 训练集和验证集的预测框各项损失曲线

由图 4.5 可知，随着训练的进行迭代次数不断增加，上述的三项损失在训练集和验证集上均呈现出持续降低的趋势，说明模型在不断学习并逐步提升检测精度。该过程主要依赖于反向传播算法，通过不断调整模型权重来优化候选框的位置参数，判断候选区域是否包含目标，并给出目标所属种类的概率。整体来看，该过程较为稳定，损失收敛较好，学习能力和泛化能力较强。

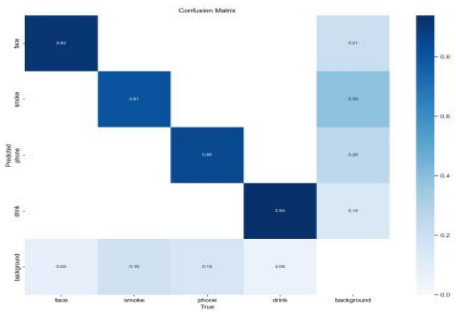

图 4.6 置信度矩阵

训练置信度矩阵如图 4.6 所示，模型在 face、phone 和 drink 类别上的表现较好，但在 smoke 类别上存在一定的误分类。而且模型的精度及召回率均表现出色，训练部分指标如图 4.7 所示，这反映出模型在检测任务上的性能相当优异。通过分析混淆矩阵和损失曲线，可以看出模型在训练的过程中不断改进，最终取得了较好的检测效果。

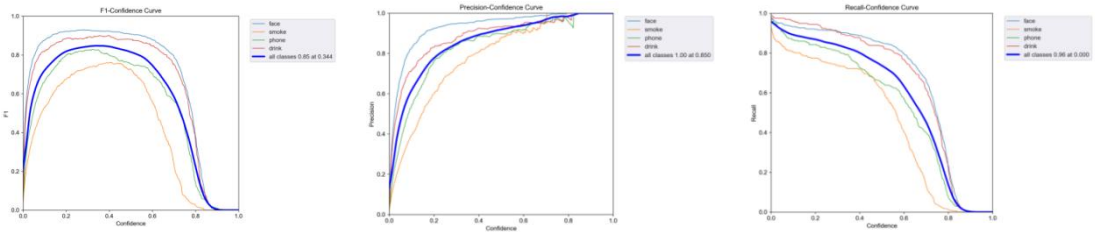

（a）F1 分数 （b）精度-置信度曲线 （c）召回-置信度曲线

图 4.7 训练部分指标结果

YOLO_S 模型的精度、召回率以及 mAP 值如图 4.8 所示，训练结果逐步趋于收敛。mAP 是模型对于多个类的综合评判指标，总体来看，模型 mAP 越接近 1 效果越好，根据图中结果分析可知，模型在各检测指标上表现良好，能够有效满足驾驶员分心行为识别系统对检测准确性和稳定性的应用需求。

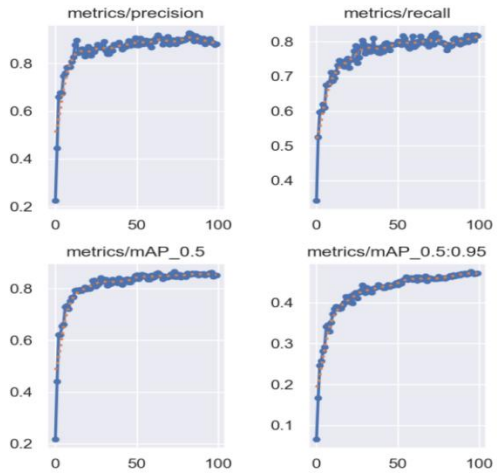

图 4.8 模型的精确度、召回率、mAP 曲线

5 总结与展望

5.1 总结

本系统设计并实现了一种基于计算机视觉的驾驶员行为监测系统，旨在应对因疲劳驾驶和分心操作引发的交通安全问题。系统综合运用了基于 Dlib 的人脸特征点分析方法及基于 YOLO 模型的危险驾驶行为检测算法，实现了对驾驶员喝水、吸烟、打电话等分心行为以及疲劳状态的有效监测。

在疲劳行为检测方面，本系统利用 Dlib 库提取人脸关键点，通过分析眼睛纵横比、嘴部开合度及头部姿态角度等面部特征，实时监测驾驶员的疲劳状态。系统能够准确识别眨眼、打哈欠等典型的疲劳驾驶表现，并根据设定的阈值触发预警机制。

在分心行为检测方面，本系统将 YOLO 与注意力机制相结合，构建了一个高效的分心行为识别框架。通过对 YOLO 检测网络进行改进，增强了对小目标物体如香烟、手机等的检测能力，同时通过注意力机制优化了目标与驾驶员动作的关联性分析。系统不仅能够识别出驾驶员手中持有的物品，还能分析驾驶员的操作动作，准确判断是否存在喝水、吸烟或打电话等分心行为。

具体而言，YOLO 算法能够准确检测出与分心行为相关的目标物体，Dlib 库则为疲劳检测提供了可靠的面部特征分析手段。成功开发了一个集多功能于一体、性能优异的驾驶员行为监测系统。

5.2 不足与展望

本系统所设计驾驶员行为监测系统取得了一定的效果，但也存在着一定的缺陷和不足，如当驾驶员出现戴口罩、墨镜等特殊装备或者面部遮挡等情况，系统识别的准

确度会受到影响，出现识别结果不够准确的情况；目前系统主要对驾驶员的疲劳行为（如打哈欠、眨眼、瞌睡点头）进行识别，对其他身体动作关注度不高，容易忽略一些与驾驶安全相关的行为。

针对以上不足，未来的研究可以从以下几个方向着手：一是针对特殊情况仍可以获取面部信息，如研究在驾驶员佩戴口罩等情况下仍能获取面部特征信息，或者结合其他传感器信息（如车辆行驶数据、车内环境数据等）进行综合分析，更加全面地监测驾驶员行为。二是增加系统的检测范围，不仅要关注疲劳行为，还需加强对驾驶员身体其他部位动作的分析，如手部操作、肢体姿态等，可以更全面地保障驾驶安全。

致 谢

在完成本篇论文的过程中，我收获了诸多宝贵的支持与帮助，这些都成为我顺利完成学业的重要力量。在此，我衷心感谢每一位给予我帮助的人。

首先，我向我的指导老师黄继海教授致以最诚挚的感谢。从论文的选题构思到文献资料的筛选整理，再到论文的反复修改与完善，黄继海教授始终耐心陪伴，悉心指导。面对我的每一个疑问，都毫无保留地分享知识与经验，为我答疑解惑。黄继海教授严谨的教学态度、渊博的专业知识以及高度的责任心，不仅在学术上为我点亮了前行的灯塔，更在为人处世方面为我树立了榜样，让我受益终生。

其次，我还要感谢学院里所有教导过我的老师。每位老师都以独特的教学风格和扎实的学识，为我打开了知识的大门，使我在专业领域不断探索前行。正因为有他们的悉心教导，我学会了从多角度分析问题，更学会了如何在学习和生活中坚守原则、追求卓越。这些宝贵的经验和品质，成为我人生中不可或缺的财富，激励我不断前行。

最后，还要特别感谢在论文写作过程中给予帮助的学长学姐们。他们在我最迷茫和无从下手的时候，及时分享了许多实用的写作技巧和研究方法，因而让我少走了不少弯路。他们的经验是极具参考价值的，更难得的是他们的态度真诚而耐心，使我深刻体会到学术传承中的温暖与力量。正是这种积极的榜样作用，让我更加坚定了继续深入研究、不断提升自我的信心和动力。

再次感谢所有给予我帮助的人，是你们让我在学术的道路上不再孤单，让我有勇气面对各种挑战。我将带着你们的期望和鼓励，继续努力，不断前行，用所学所知为社会贡献自己的力量。

参考文献

[1] 吴博峰. 全国机动车保有量达 4.53 亿辆[N]. 中国消费者报, 2025-01-21 (004).

[2] 国家统计局.中华人民共和国 2024 年国民经济和社会发展统计公报[N].人民日报,2025-03-01(005).

[3] 朱敏慧.大陆集团调研：驾驶分心是导致青年驾驶者交通事故的最主要原因[J]. 汽车与配件,2021,(15):32-33.

[4] Zhang, Chaoyun et al. “Driver Behavior Recognition via Interwoven Deep Convolutional Neural Nets With Multi-Stream Inputs.” IEEE Access 8 (2018): 191138-191151.

[5] Kose, Neslihan, Okan Köpüklü, Alexander Unnervik and Gerhard Rigoll. “Real-Time Driver State Monitoring Using a CNN Based Spatio-Temporal Approach*.” 2019 IEEE Intelligent Transportation Systems Conference (ITSC) (2019): 3236-3242.

[6] Jha, Sumit Kumar et al. “The Multimodal Driver Monitoring Database: A Naturalistic Corpus to Study Driver Attention.” IEEE Transactions on Intelligent Transportation Systems 23 (2020): 10736-10752.

[7] 曹骏. 面向嵌入式平台的汽车驾驶员疲劳驾驶检测系统的设计与实现[D]. 成都：西南交通大学, 2023.

[8] 胡敏. 基于视觉的驾驶员注意力检测与判别研究[D]. 长沙：湖南大学, 2018.

[9] 陈华. 面向智能辅助驾驶系统的驾驶员行为分析与建模[D]. 长春：吉林大学, 2018.

[10] 王国栋. 基于多模态特征融合的驾驶员疲劳检测方法研究[D]. 济南：山东大学, 2020.

[11] 刘肖. 面向驾驶员状态监测的动态生理信号质量评估研究[D]. 福州：福建工程学院, 2021.

[12] 沈帅杰. 基于轻量化MNG-YOLO模型的疲劳驾驶检测研究[D]. 太原：太原师范学院, 2024.

[13] Lee, Hee Seok, and Kang Kim. "Simultaneous traffic sign detection and boundary estimation using convolutional neural network." IEEE Transactions on Intelligent

Transportation Systems 19.5 (2018): 1652-1663.

[14] 吕双双. 机器学习在荧光光谱识别与光学治疗细胞活性评估中的应用[D]. 北京：北京邮电大学, 2024.

[15] 戈若男. 驾驶员疲劳状态识别方法研究[D]. 沈阳：沈阳工业大学, 2024.

[16] 刘琳. 驾驶员分心和疲劳行为检测算法研究[D]. 武汉：中南民族大学, 2023.

[17] 李王蔚,周丽丽. 基于人脸特征的疲劳驾驶检测系统设计与实现 [J]. 科技风, 2025, (05): 4-6.

[18] 张婧. 基于面部视觉特征融合的疲劳驾驶检测算法研究[D]. 沈阳：沈阳工业大学, 2024.

[19] 许华胜. 基于计算机视觉的驾驶员行为分析系统设计[D]. 青岛：青岛大学, 2019.

[20] 陈林泉. 基于dlib模型与头部姿态估计实现实时疲劳检测[D]. 福州：福建师范大学, 2021.

[21] 赵凯鑫. 基于驾驶员监控系统的危险驾驶行为检测研究[D]. 天津：天津科技大学, 2022.

[22] 陈威. 基于深度学习的驾驶分心行为识别研究[D]. 武汉：武汉理工大学, 2022.

[23] 沈倩. 驾驶员危险驾驶行为检测及预警系统研究[D]. 西安：长安大学, 2023.

[24] 包辛煜. 基于深度学习的驾驶员分心行为检测[D]. 长沙：湖南大学, 2023.